

Лабораторная работа № 4

Иерархическая и вероятностная кластеризации

Исходные данные: имеется 2 датасета: один в виде наборов координат в двумерном пространстве, второй имеет прикладной характер (т.е. из реальных исследований, размещённых в Kaggle).

Первый датасет находится в корневом каталоге варианта, представлен набором точек x , y . Набор данных используется для выполнения заданий 2-4, 7.

Второй датасет расположен в папке внутри корневого каталога варианта. Описание датасета хранится в файле Context.docx (англ.). Набор данных используется для выполнения заданий 5-7.

Второй датасет (в теории, и первый) можно заменить другим с предварительным согласованием у преподавателя.

Задание:

1. Изучить датасеты и определить, нужно ли проводить нормализацию имеющихся данных, и выполнить её при необходимости. Если не уверены, стоит ли это делать, just do it.
2. Определить число кластеров, построив дендрограмму.
3. Построить график зависимости расстояний между кластерами от шага слияния. Определить по графику оптимальное число кластеров.
4. Выбрать оптимальный алгоритм и выполнить кластеризацию. Пробуйте разные варианты, чтобы определить наиболее подходящий вариант.

5. Определить число кластеров для прикладного датасета методом расчёта сумм расстояний от точек данных до центра ближайшего к ней кластера (инерций). Для кластеризации используйте как исходный датасет без предобработки, так и с предобработкой, выполненной в лабораторной работе 3.
6. Выполнить кластеризацию методом k-средних для прикладного датасета.
7. Провести анализ полученных результатов из заданий 4 и 6, и сформулировать отличительные особенности разных кластеров для прикладного датасета.
8. Оцените интерпретируемость кластеров, полученных как от предобработанного датасета, так и исходного.

Критерии:

Критерий	Описание критерия	Выполнено	Выполнено частично	Не выполнено
Выполнение кластеризации	Применение оптимального алгоритма кластеризации. Обязательный к выполнению.	Проведена кластеризация, группа обосновала применяемый алгоритм.	-	Кластеризация не проведена или группа не смогла прокомментировать используемый алгоритм.
Проведение анализа результатов кластеризации	Выявление отличительных особенностей каждого кластера. Обязательный к выполнению.	Группа выявила отличительные черты каждого полученного кластера, продемонстрировав аналитические навыки.	-	Группа не смогла прокомментировать результат кластеризации.
Нормализация данных	Применение нормализации при необходимости.	Нормализация выполнена или доказано, что она не требуется (4 балла)	-	Нормализация не выполнена при условии её необходимости. (0 баллов)

Определение числа кластеров по дендрограмме.	Построение дендрограммы, демонстрация её анализа.	Дендрограмма построена, число кластеров по ней определено корректно. (2 балла)	Дендрограмма построена, но число кластеров определено некорректно. (1 балл)	Дендрограмма не построена. (0 баллов)
Анализ графика зависимости расстояний	Построение графика зависимости межкластерных расстояний от шага слияния с определением числа кластеров по нему.	График построен, число кластеров по нему определено корректно. (2 балла)	График построен, но число кластеров определено некорректно. (1 балл)	График отсутствует. (0 баллов)
Кластеризация методом k-средних.	Проведение кластеризации методом k-средних и её анализ.	Кластеризация проведена, группа пояснила её результаты (3 балла)	Кластеризация проведена, группа не смогла пояснить её результаты. (1 балл)	Кластеризация методом k-средних не проведена. (0 баллов)

Ответ на вопрос преподавателя	Студент даёт определение метрике расстояния между объектами с её математической формулой или алгоритму кластеризации на выбор преподавателя.	Студент дал полное и ясное определение метрике с её математической формулой или алгоритму кластеризации. (2 балла)	Студент дал определение метрике с её математической формулой или алгоритму кластеризации с незначительными ошибками (1 балл)	Студент не смог дать правильное определение метрике с её математической формулой или алгоритму кластеризации. (0 баллов)
---	---	--	--	--